MC920 – Introdução ao Processamento Digital de Imagem
Trabalho 3

Rafael Eiki Matheus Imamura - RA 176127[1]

[1]Instituto de Computação – Universidade Estadual de Campinas (Unicamp)
Caixa Postal 6176 – CEP 13083-970 – Campinas – SP – Brasil

ra176127@students.ic.unicamp.br

1. Introdução

Uma atividade que é cada vez mais comum, com a popularização de dispositivos celulares com câmeras, é tirar fotos de documentos. Isso pode acontecer desde digitalização de documentos até anotação rápida de informações. Em muitos desses casos, é interessante a detecção de conteúdo textual presente na imagem. Um primeiro passo para usar uma tecnologia de detecção de caracteres (Optical Character Recognition – OCR) é conseguir segmentar uma imagem em linhas e palavras.

Neste trabalho, foi criado um algoritmo para detecção de palavras e linhas de texto em uma imagem binária no formato PBM (Portable BitMap). As imagens foram testadas com o algoritmo e os resultados e escolhas do algoritmo são descritos a seguir.

2. Execução

A entrega deste trabalho inclui o presente PDF e um diretório de nome "projeto 3". Nela se encontram o código, as dependências e as imagens de entrada usadas para os testes.

Para executar o código, deve-se ter instalado o OpenCV e o Numpy. Um *freeze* das dependências está presente no arquivo "requirements.txt". Uma alternativa rápida para fazer a instalação é o comando:

pip install -r requirements.txt

Com este comando instalado, basta chamar o arquivo de script com o parâmetro desejado:

*python main.py *opções arquivo_de_entrada arquivo_de_saida flags*

O significado de cada parâmetro da entrada é:

1. *Opções*: parâmetro opcional:
    a. *example*: gera todas os casos de exemplo (diretório "pictures").
2. *Arquivo_de_entrada*: caminho para a imagem base. Este parâmetro não é usado para a opção *example*.
3. *Arquivo_de_saida*: caminho para o arquivo de saída da imagem. A opção *example* não usa este parâmetro – as imagens são geradas no diretório "results".
4. *Flags*: caso exista, é aplicado o efeito definido:

a. *-a*: usa o algoritmo do limiar ao invés do operador morfológico para o passo 10 (mais explicações a frente).

Alguns exemplos de uso são mostrados a seguir:

1. python main.py example
2. python main.py./pictures/text.pbm ./results/text.pbm
3. python main.py ./pictures/text.pbm ./teste.pbm -a

2.1. Entrada

A entrada, em todos os casos, é dada por imagens PBM. Para este relatório, foram usadas 6 imagens, das quais uma foi fornecida no enunciado do trabalho (*http://www.ic.unicamp.br/~helio/imagens_morfologia/*), imagens do diretório PBMA e capturas de tela de um artigo (autoria própria) e um livro (domínio público).

Todas as entradas usadas estão disponíveis dentro do zip, no diretório "pictures".

2.2. Saída

A saída do programa são imagens no formato PBM binária (P4) e a quantidade de palavras e linhas encontradas na saída do programa. 1 na imagem representa preto, enquanto 0 representa branco. A imagem de saída possui cada palavra encontrada contornada por um retângulo preto.

3. Solução

O método adotado segue as indicações do enunciado do trabalho até o passo 6:

1. Dilatação da imagem original com um elemento estruturante de 1 pixel de altura e 100 pixels de largura;
2. Erosão da imagem resultante com o mesmo elemento estruturante do passo (1);
3. Dilatação da imagem original com um elemento estruturante de 200 pixels de altura e 1 pixel de largura;
4. Erosão da imagem resultante com o mesmo elemento estruturante do passo (3);
5. Aplicação da intersecção (AND) dos resultados dos passos (2) e (4);
6. Fechamento do resultado obtido no passo (5) com um elemento estruturante de 1 pixel de altura e 30pixels de largura.

O passo 7 pede a identificação de componentes conexos. Foi usado o programa fornecido (*comp_conexos.c*) com uma modificação: é escrito na saída do programa as coordenadas dos 2 pontos que definem cada retângulo das componentes conexas. A saída do programa é então redirecionada para um arquivo, que é lido e processado para realizar o passo 8.

7. Uso do programa modificado para detectar componentes conexas;
8. Cálculo da quantidade de pixels pretos, proporção quanto a área total e quantidade de transições;
9. Classificação das componentes como texto e não-texto, feito usando as proporções de pixels pretos e transições horizontais e verticais;
10. Segmentação das linhas em blocos de palavras.

Os intervalos de valores aceitos no passo 9 foram usados com análises das saídas do programa para diferentes imagens. Para o passo 10, a segmentação foi feita usando o operador morfológico de fechamento, com elemento estruturante de altura 2 vezes maior

que a altura da linha e largura proporcional a parte da altura da linha. Isso foi feito pensando que a altura da linha determina aproximadamente o tamanho da fonte usada, e o espaço entre as palavras será aproximadamente proporcional à fonte. Os valores exatos foram testados empiricamente com as imagens. Mais desses testes serão descritos mais adiante.

4. Resultados

As imagens resultantes passaram por diversos processos. A seguir são mostrados alguns passos a fim de clarificar o algoritmo criado. A imagem "text.pbm" será usasda como o principal exemplo (Figura 1).

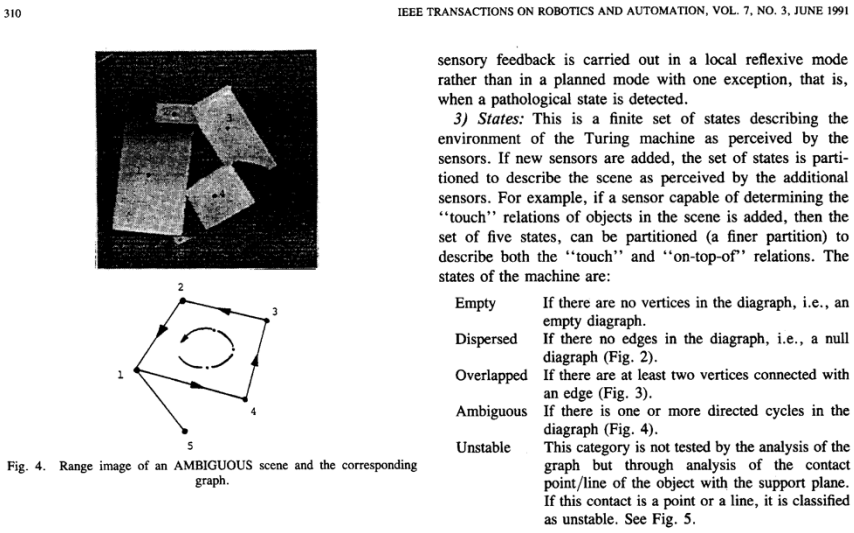

310 IEEE TRANSACTIONS ON ROBOTICS AND AUTOMATION, VOL. 7, NO. 3, JUNE 1991

Fig. 4. Range image of an AMBIGUOUS scene and the corresponding graph.

sensory feedback is carried out in a local reflexive mode rather than in a planned mode with one exception, that is, when a pathological state is detected.

3) States: This is a finite set of states describing the environment of the Turing machine as perceived by the sensors. If new sensors are added, the set of states is partitioned to describe the scene as perceived by the additional sensors. For example, if a sensor capable of determining the "touch" relations of objects in the scene is added, then the set of five states, can be partitioned (a finer partition) to describe both the "touch" and "on-top-of" relations. The states of the machine are:

Empty	If there are no vertices in the diagraph, i.e., an empty diagraph.
Dispersed	If there no edges in the diagraph, i.e., a null diagraph (Fig. 2).
Overlapped	If there are at least two vertices connected with an edge (Fig. 3).
Ambiguous	If there is one or more directed cycles in the diagraph (Fig. 4).
Unstable	This category is not tested by the analysis of the graph but through analysis of the contact point/line of the object with the support plane. If this contact is a point or a line, it is classified as unstable. See Fig. 5.

Figura 1. Versão original de "text.pbm".

Os 6 primeiros passos do programa seguem o padrão sugerido no enunciado. Quando terminado, esses 6 passos são consolidados em uma imagem temporária intermediária (Figura 2), usada pelo programa *comp_conexos.c*.

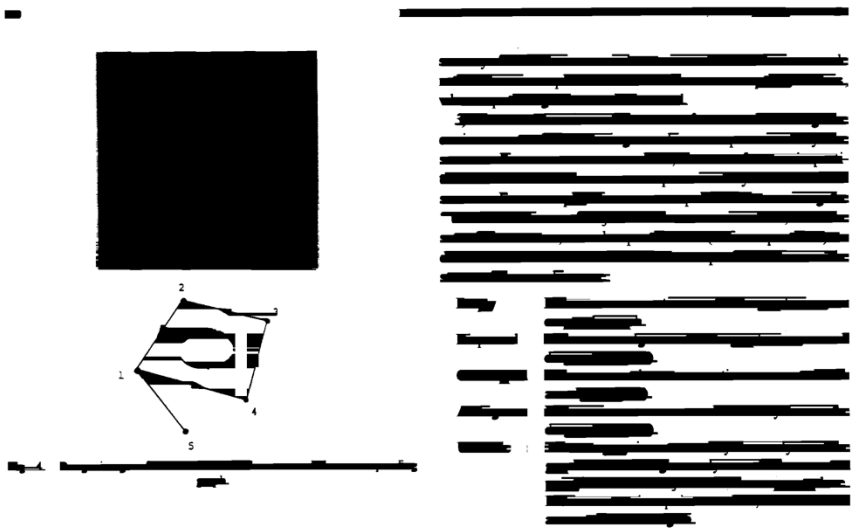

Figura 2. Resultado dos 6 primeiros passos em "text.pbm".

O estado dessa imagem (Figura 2) foi usado para verificar quais seriam os componentes que poderiam ser descobertos ou não. Nesse exemplo, é possível ver o que número “3”, próximo aos números 1, 2, 4 e 5, foi fundido com a figura. Assim, ele não poderia ser descoberto como um caractere posteriormente.

O resultado do passo 7 é dado em texto e em imagem. Neste exemplo, foram encontradas 53 componentes conexas e a imagem resultante pode ser vista na Figura 3.

Figura 3. Retângulos envolvem cada componente conexa de “text.pbm”.

Para classificação em texto, a seguinte regra foi aplicada em cada componente:

$$0.2 <= BP <= 0.6, VT < 0.8, HT < 0.8 \quad OR \quad VT > 0.5, HT > 0.5, BP > 0.12$$

Onde:

- BP é a proporção de pixels pretos pela área da componente;
- VT é a razão de transições verticais de branco para preto (percorrendo de cima para baixo) e o total de pixels pretos;
- HT é a razão de transições horizontais de branco para preto (percorrendo da esquerda para a direita) e o total de pixels pretos.

A quantidade de textos nas componentes representava aproximadamente essa quantidade de texto, enquanto a quantidade de transições verticais e horizontais não poderia ser excessiva para a imagem “text.pbm”. No entanto, comparando com as demais imagens, em alguns casos, uma quantidade de pixels pretos poderia ser menor quando as transições verticais e hortizontais eram mais frequentes. Com essa classificação de texto, todos os textos presentes em componentes identificados no passo 7 foram encontrados.

Para a detecção de palavras, foram desenvolvidos 2 algoritmos: um que considera o desvio padrão do tamanho dos espaços e cria um limiar para ver quais são espaços entre caracteres e quais são entre palavras; e outro, que usa o operador morfológico de fechamento.

O algoritmo que usa o limiar parte da ideia de que existem 2 tipos de espaços nas linhas de texto: espaços entre caracteres (que são consideravelmente menores) e espaços entre palavras. Para escolher o limiar, é calculado o tamanho de todos os espaços (os espaços são considerados quando a quantidade de pixels pretos na vertical é baixa (menos

de 5% da altura da componente). O limiar é a média dos tamanhos. Foi tentado usar a mediana, mas os resultados foram significamente piores. Espaços acima do limiar são espaços entre palavras. Para saber se o componente é uma única palavra, é checado se o desvio é pelo menos um pouco acima do limiar, tendo assim uma diferença grande entre o tamanho dos espaços.

O algoritmo que usa o operador morfológico aplica um fechamento em cada componente conexa de texto a fim de transformar cada palavra em blocos. O elemento estruturante é de:

- Altura: 2 vezes a altura da componente;
- Largura: $\lceil 0.22 * altura\ da\ componente + 0.62 \rceil$

A altura é usada para dilatar o texto para a altura toda da componente. A largura é justificada como o tamanho aproximado do espaço para a fonte. A constante 0.62 é usada para calcular o tamanho mínimo de espaço, independente do tamanho da fonte.

Depois de ter esses blocos, é aplicado o algoritmo do limiar, com o valor forçado a ser 0, aceitando qualquer espaço existente. Um exemplo do resultado do processo de criação dos blocos pode ser visto na Figura 4.

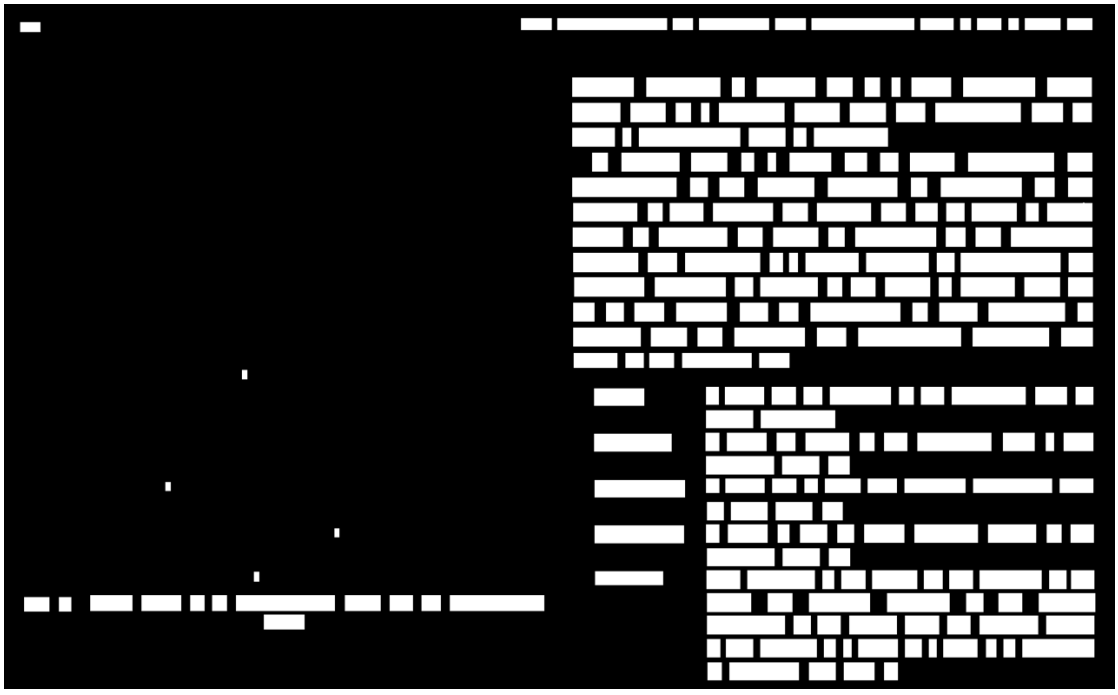

Figura 4. "text.pbm" após ser aplicado o fechamento em cada componente.

Os resultados de cada algoritmo para essa entrada são:

1. Com limiar: 40 linhas e 246 palavras (Figura 5);
2. Com operador morfológico: 40 linhas e 242 palavras (Figura 6).

A Figura 5 possui maiores erros. O título é juntado todo em uma palavra só, e a pontuação é separada como uma palavra a parte em diversos casos, como nas aspas e vírgulas após pontos. No entanto, ele é um algoritmo que é mais rápido, não sendo necessário a aplicação de um operador morfológico e tendo um erro não muito grande

neste caso em específico (de 10 palavras detectadas como 1 e 13 pontuações detectadas como palavras). A Figura 6 detectou precisamente todas as palavras e suas pontuações.

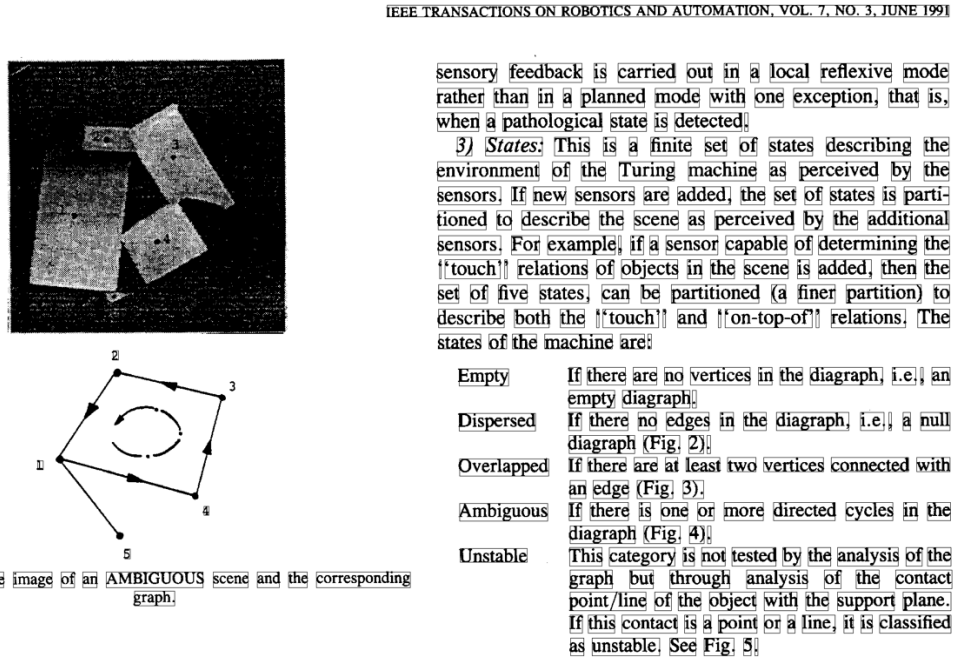

310 IEEE TRANSACTIONS ON ROBOTICS AND AUTOMATION, VOL. 7, NO. 3, JUNE 1991

Fig. 4. Range image of an AMBIGUOUS scene and the corresponding graph.

sensory feedback is carried out in a local reflexive mode rather than in a planned mode with one exception, that is, when a pathological state is detected.

3) States: This is a finite set of states describing the environment of the Turing machine as perceived by the sensors. If new sensors are added, the set of states is partitioned to describe the scene as perceived by the additional sensors. For example, if a sensor capable of determining the ⁅"touch"⁆ relations of objects in the scene is added, then the set of five states, can be partitioned (a finer partition) to describe both the ⁅"touch"⁆ and ⁅"on-top-of"⁆ relations. The states of the machine are:

Empty	If there are no vertices in the diagraph, i.e., an empty diagraph.
Dispersed	If there no edges in the diagraph, i.e., a null diagraph (Fig. 2).
Overlapped	If there are at least two vertices connected with an edge (Fig. 3).
Ambiguous	If there is one or more directed cycles in the diagraph (Fig. 4).
Unstable	This category is not tested by the analysis of the graph but through analysis of the contact point/line of the object with the support plane. If this contact is a point or a line, it is classified as unstable. See Fig. 5.

Figura 5. Resultado final de "text.pbm" usando o limiar no passo 10.

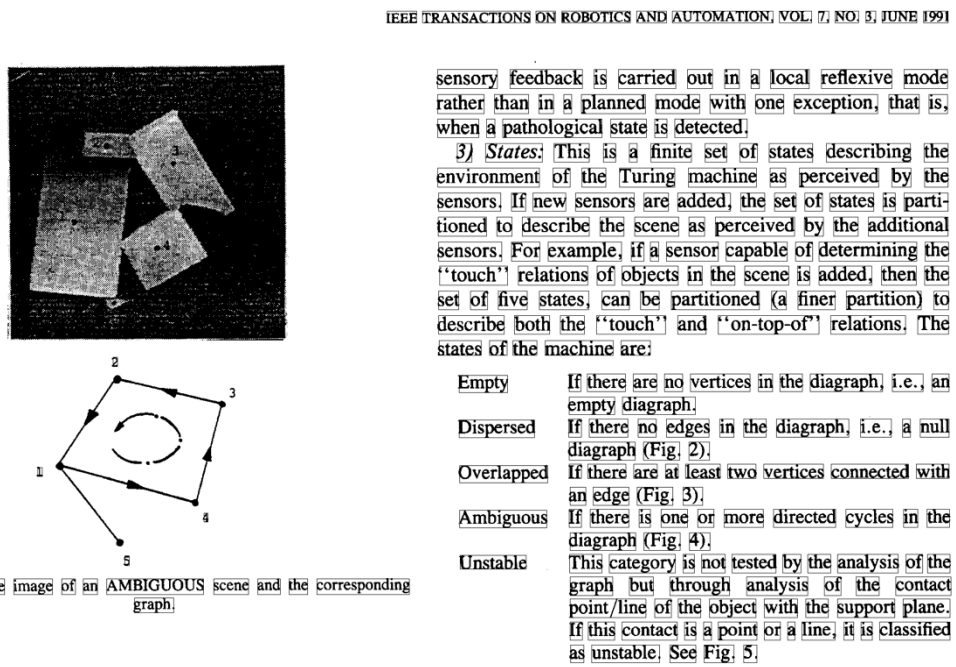

310 IEEE TRANSACTIONS ON ROBOTICS AND AUTOMATION, VOL. 7, NO. 3, JUNE 1991

Fig. 4. Range image of an AMBIGUOUS scene and the corresponding graph.

sensory feedback is carried out in a local reflexive mode rather than in a planned mode with one exception, that is, when a pathological state is detected.

3) States: This is a finite set of states describing the environment of the Turing machine as perceived by the sensors. If new sensors are added, the set of states is partitioned to describe the scene as perceived by the additional sensors. For example, if a sensor capable of determining the "touch" relations of objects in the scene is added, then the set of five states, can be partitioned (a finer partition) to describe both the "touch" and "on-top-of" relations. The states of the machine are:

Empty	If there are no vertices in the diagraph, i.e., an empty diagraph.
Dispersed	If there no edges in the diagraph, i.e., a null diagraph (Fig. 2).
Overlapped	If there are at least two vertices connected with an edge (Fig. 3).
Ambiguous	If there is one or more directed cycles in the diagraph (Fig. 4).
Unstable	This category is not tested by the analysis of the graph but through analysis of the contact point/line of the object with the support plane. If this contact is a point or a line, it is classified as unstable. See Fig. 5.

Figura 6. Resultado final de "text.pbm" usando o operador morfológico no passo 10.

Alguns outros exemplos de imagens usadas para os testes são mostrados a seguir. Em todos os casos, foi aplicado o operador morfológico para encontrar as palavras.

Figura 7. Entrada e saída para a imagem "letter_a.pbm".

Figura 8. Entrada e saída para a imagem "scs.pbm".

As Figuras 7 e 8 foram perfeitamente detectadas. São casos de letras grandes e uma única palavra presente na imagem.

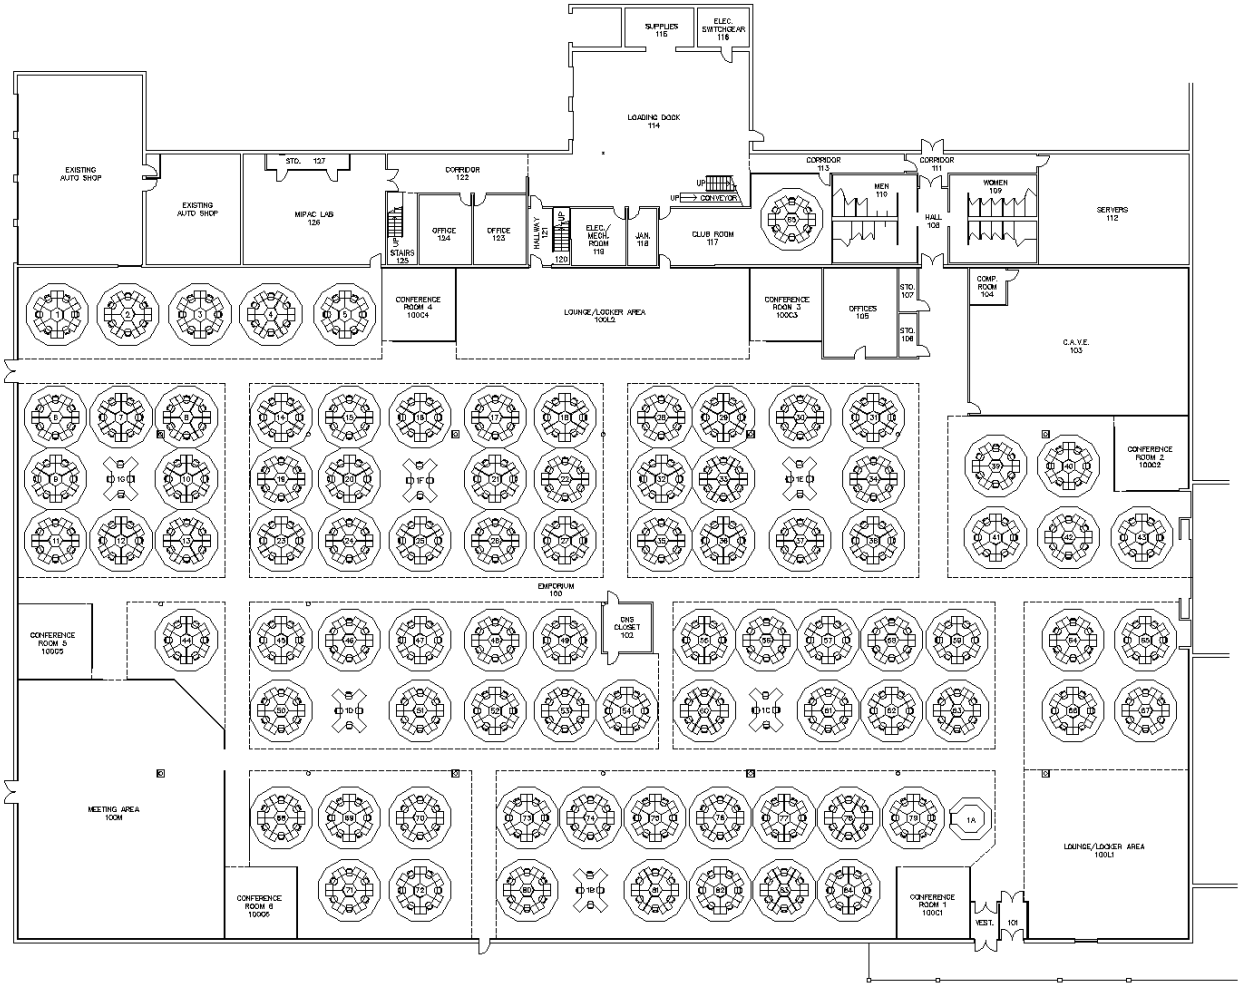

Figura 9. Imagem original de entrada "map.pbm".

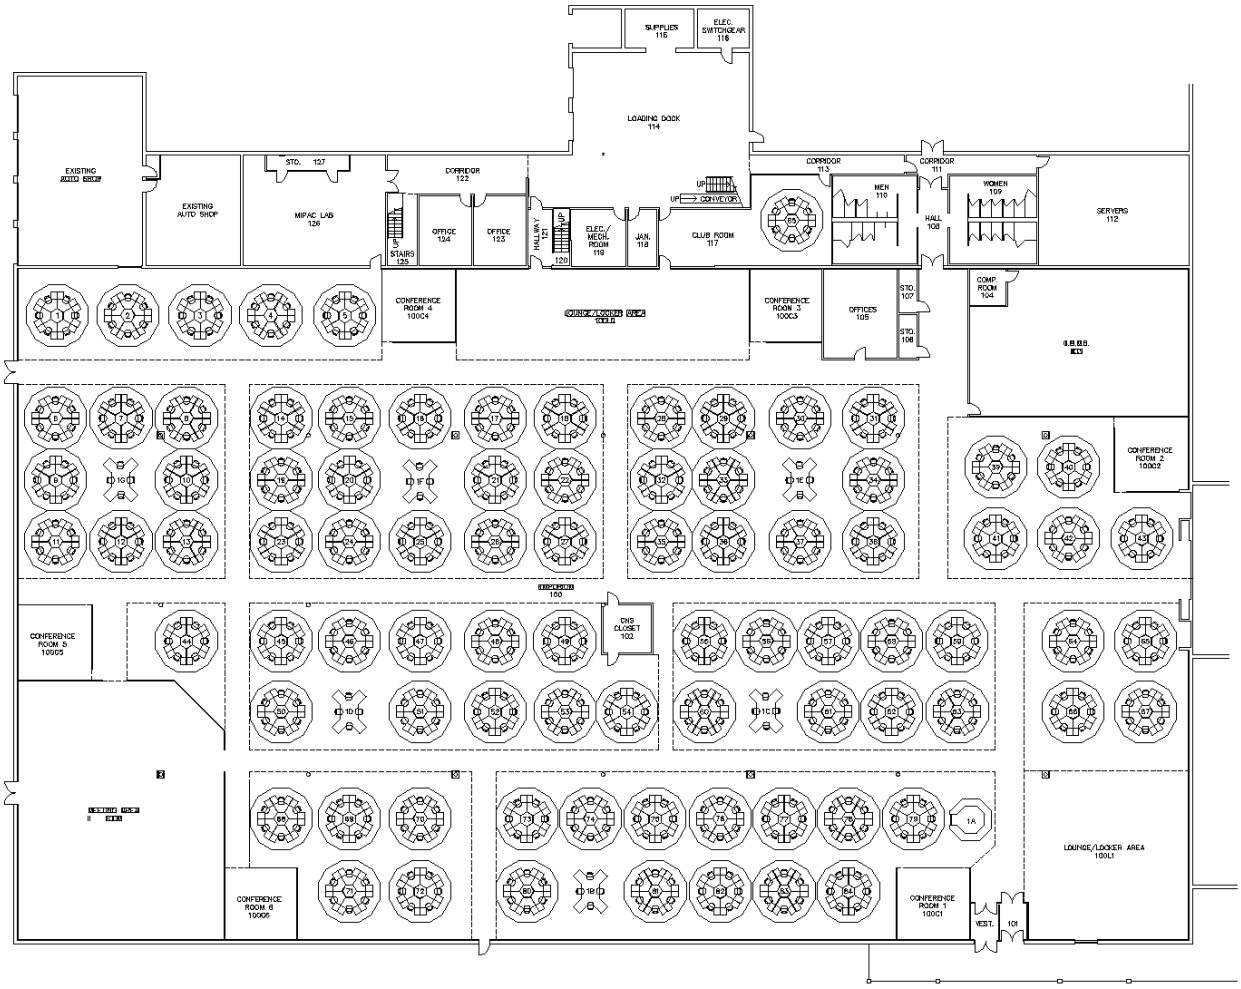

Figura 10. Imagem de saída para "map.pbm".

As Figuras 9 e 10 apresentam um caso complexo, com diferentes padrões misturados com letras pequenas em disposições diferentes. O algoritmo foi capaz de detectar 9 linhas com 18 palavras, espalhadas em posições como a parte inferior esquerda, central superior, e no centro. É um caso particularmente difícil, mas que foi possível ainda assim extrair alguns dados.

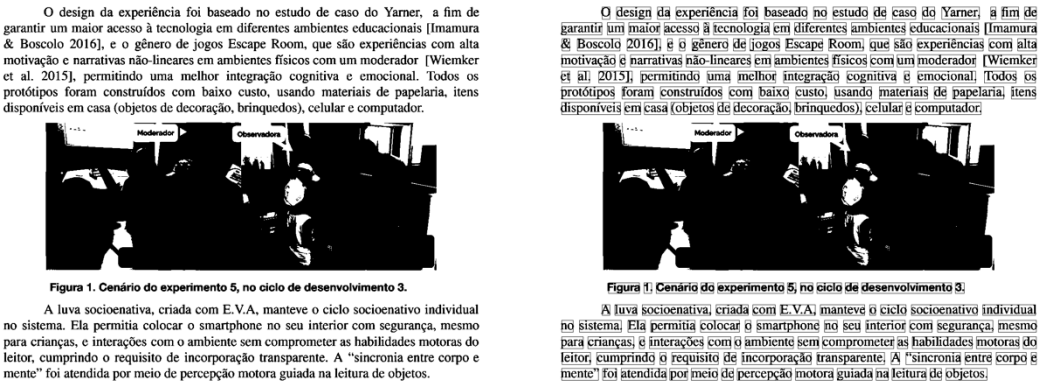

O design da experiência foi baseado no estudo de caso do Yarner, a fim de garantir um maior acesso à tecnologia em diferentes ambientes educacionais [Imamura & Boscolo 2016], e o gênero de jogos Escape Room, que são experiências com alta motivação e narrativas não-lineares em ambientes físicos com um moderador [Wiemker et al. 2015], permitindo uma melhor integração cognitiva e emocional. Todos os protótipos foram construídos com baixo custo, usando materiais de papelaria, itens disponíveis em casa (objetos de decoração, brinquedos), celular e computador.

Figura 1. Cenário do experimento 5, no ciclo de desenvolvimento 3.

A luva socioenativa, criada com E.V.A, manteve o ciclo socioenativo individual no sistema. Ela permitia colocar o smartphone no seu interior com segurança, mesmo para crianças, e interações com o ambiente sem comprometer as habilidades motoras do leitor, cumprindo o requisito de incorporação transparente. A "sincronia entre corpo e mente" foi atendida por meio de percepção motora guiada na leitura de objetos.

O design da experiência foi baseado no estudo de caso do Yarner, a fim de garantir um maior acesso à tecnologia em diferentes ambientes educacionais [Imamura & Boscolo 2016], e o gênero de jogos Escape Room, que são experiências com alta motivação e narrativas não-lineares em ambientes físicos com um moderador [Wiemker et al. 2015], permitindo uma melhor integração cognitiva e emocional. Todos os protótipos foram construídos com baixo custo, usando materiais de papelaria, itens disponíveis em casa (objetos de decoração, brinquedos), celular e computador.

Figura 1. Cenário do experimento 5, no ciclo de desenvolvimento 3.

A luva socioenativa, criada com E.V.A, manteve o ciclo socioenativo individual no sistema. Ela permitia colocar o smartphone no seu interior com segurança, mesmo para crianças, e interações com o ambiente sem comprometer as habilidades motoras do leitor, cumprindo o requisito de incorporação transparente. A "sincronia entre corpo e mente" foi atendida por meio de percepção motora guiada na leitura de objetos.

Figura 11. Entrada e saída para "paper.pbm".

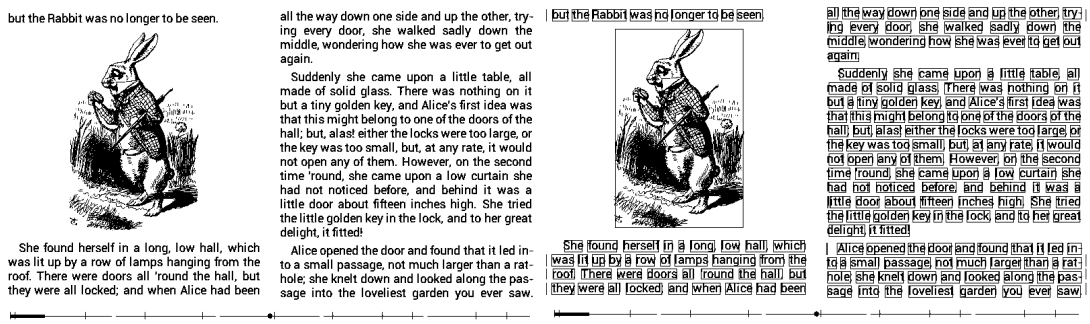

Figura 12. Entrada e saída da imagem “rabbit.pbm”.

Nas Figura 11 e 12 ocorrem os casos mais “comuns”, em que há texto e figuras nas imagens. Na Figura 11, é mostrado um artigo (autoria própria), em que o texto foi perfeitamente detectado, tanto as linhas como as palavras (14 linhas, 159 palavras). Já na Figura 12, o desenho do coelho foi detectado como uma palavra, totalizando 26 linhas e 220 palavras, o único caso de falso positivo dos casos de teste.

Aplicando a versão do algoritmo que usa o limiar nas imagens “paper.pbm” e “rabbit.pbm” a diferença é bem grande. Os resultados podem ser vistos na Tabela 1.

Tabela 13. Comparação do algoritmo de classificação com limiar e operador morfológico.

Imagem	Linhas	Palavras (limiar)	Palavras (operador)
text.pbm	40	246	242
letter_a.pbm	1	1	1
scs.pbm	1	1	1
map.pbm	9	10	18
paper.pbm	14	98	159
rabbit.pbm	26	33	220

5. Conclusões

Este trabalho apresentou um algoritmo para detecção de palavras e linhas em imagens binárias no formato PBM. Foram criadas 2 variações do algoritmo, usando o operador morfológico e uma versão mais simples. A versão com o operador morfológico obteve resultados melhores, enquanto a versão usando limiar possui um desempenho maior. Em alguns casos, a diferença nos resultados foi bastante grande.

As imagens testadas apresentaram alguns casos de falso negativo, como na imagem “map.pbm”. Esses casos parecem estar atrelados a textos com fontes pequenas, próximas a outras figuras. Apenas um caso de falso positivo foi encontrado, na imagem “rabbit.pbm”. Uma limitação dos testes é que os textos estavam alinhados horizontalmente para serem detectados.

De forma geral, os resultados são bastante satisfatórios. Para detecção de palavras em tamanhos e espaçamento regulares, o algoritmo funcionou bem. Adaptações podem

ser necessárias para determinadas imagens, mas no algoritmo proposto ele faz um trabalho genérico bastante razoável.

Para ser usado em situações mais genéricas, o algoritmo precisaria analisar outros possíveis problemas das imagens, como desalinhamento do texto, fontes pequenas e textos próximos de imagens.

Referências

OpenCV. (2015) "OpenCV Documentation". Disponível em: <https://docs.opencv.org/>. Acesso em: mai. 2019.

PGBA. (2011) "PBMA data directory". Disponível em: < https://people.sc.fsu.edu/~jburkardt/data/pbma/pbma.html>. Consulta em mai. 2019.

SciPy.org. (2019) "NumPy Reference". Disponível em: < https://docs.scipy.org/doc/numpy/reference/>. Acesso em: mai. 2019.